

Documentação Técnica — Tech Challenge Fase 2

Pipeline Híbrida para Análise da Alfabetização no Brasil

Instituição: FIAP PosTech

Curso: AI Scientist

Aluno: Guilherme Diniz Leocadio

Data: Julho de 2026

Repositório: <https://github.com/GuilhermeDinizLeocadio/tech-challenge-fase2>

1. Contexto do Problema

1.1 O Desafio da Alfabetização no Brasil

A alfabetização na infância é um dos pilares fundamentais para o desenvolvimento educacional, social e econômico do Brasil. Crianças que chegam ao 3º ano do ensino fundamental sem saber ler e escrever carregam essa desvantagem por toda a vida escolar, impactando diretamente suas perspectivas profissionais e sociais.

O **Compromisso Nacional Criança Alfabetizada**, instituído pelo Decreto nº 11.556 de 12 de junho de 2023, estabelece a meta de que todas as crianças brasileiras estejam alfabetizadas até o final do **2º ano do ensino fundamental até 2030**, mobilizando União, estados, Distrito Federal e municípios.

1.2 O Indicador Criança Alfabetizada

Para monitorar esse compromisso, o INEP realizou em 2023 a **Pesquisa Alfabetiza Brasil**, definindo o ponto de corte de **743 pontos na escala de proficiência do SAEB** como nível mínimo de alfabetização. Com base nesse parâmetro, foi criado o **Indicador Criança Alfabetizada**, que expressa o percentual de estudantes que atingem esse patamar.

1.3 O Problema de Dados

Os dados sobre alfabetização estão distribuídos em múltiplas fontes heterogêneas:

- Microdados das avaliações estaduais** (INEP/AEEB) — dados individuais por aluno
- Metas nacionais e regionais** (Base dos Dados) — objetivos por estado e município
- Dados territoriais** — informações geográficas e socioeconômicas

Sem uma pipeline integrada, é impossível responder perguntas estratégicas como: - Quais estados estão no caminho certo para atingir a meta de 2030? - Quais municípios precisam de intervenção urgente? - Qual é a magnitude da desigualdade regional na alfabetização? - Como a taxa de alfabetização evoluiu ao longo do tempo?

1.4 Objetivo do Projeto

Construir uma **pipeline híbrida de dados** (Batch + Streaming) que integre diferentes fontes relacionadas ao indicador de alfabetização, garantindo qualidade, escalabilidade e eficiência de custos em ambiente de nuvem AWS, produzindo datasets analíticos prontos para dashboards e modelos de Inteligência Artificial.


2. Arquitetura da Solução

2.1 Visão Geral

A solução implementa a **Arquitetura Medalhão** com três camadas de dados, combinada com uma pipeline de Streaming para eventos em tempo real, toda hospedada na AWS S3.

2.2 Diagrama da Pipeline





tech-challenge-alfabetizacao informações

Objetos

Metadados

Propriedades

Permissões

Métricas

Gerenciamento

Sistemas de arquivos (novo)

Pontos de acesso

Objetos (4)

Copiar URI do S3

Copiar URL

Fazer download

Abrir

Excluir

Ações

Criar pasta

Carregar

Os objetos são as entidades fundamentais armazenadas no Amazon S3. Você pode usar o [inventário do Amazon S3](#) para obter uma lista de todos os objetos em seu bucket. Para outras pessoas acessarem seus objetos, você precisará conceder permissões explicitamente a eles. [Saiba mais](#)

<

1

>

☐	Nome	Tipo	Última modificação	Tamanho	Classe de armazenamento
☐	bronze/	Pasta	-	-	-
☐	gold/	Pasta	-	-	-
☐	silver/	Pasta	-	-	-
☐	streaming/	Pasta	-	-	-

2.3 Componentes da Arquitetura

Componente	Tecnologia	Responsabilidade
Data Lake	AWS S3	Armazenamento das 3 camadas
Ingestão Batch	Python + Boto3	Coleta e envio dos CSVs para S3
Transformação	Python + Pandas	Limpeza e padronização

Componente	Tecnologia	Responsabilidade
Serialização	PyArrow + Parquet	Formato eficiente Silver/Gold
Streaming	Python + S3	Eventos em tempo real simulados
Qualidade	Scripts Python	Validação e monitoramento
Versionamento	Git + GitHub	Controle de código e histórico

2.4 Fluxo de Dados Detalhado

Batch (dados históricos): 1. Scripts Python coletam os CSVs das fontes originais 2. Arquivos são enviados ao S3 na camada Bronze (sem modificações) 3. Scripts de transformação lêem do Bronze, limpam e salvam na Silver em Parquet 4. Scripts de agregação lêem da Silver e criam datasets analíticos na Gold

Streaming (eventos em tempo real): 1. Producer gera eventos simulados com novos indicadores municipais 2. Eventos são salvos como JSON na fila `streaming/eventos_pendentes/` 3. Consumer processa cada evento, calcula tendência e move para `eventos_processados/` 4. Log de execução é registrado em `streaming/logs/`

3. Fontes de Dados

3.1 INEP — Microdados AEEB 2025

Fonte principal do projeto. Microdados das Avaliações Estaduais da Educação Básica de 2025, disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira.

Arquivo	Descrição	Linhas	Tamanho
TS_ALUNO.csv	Dados individuais dos alunos avaliados	2.222.792	257 MB
TS_ESTADO.csv	Resultados agregados por estado/UF	80	6 KB
TS_MUNICIPIO.csv	Resultados agregados por município	12.416	1.5 MB
TS_ITEM.csv	Itens de prova utilizados nas avaliações	1.960	193 KB

Cobertura: 27 estados brasileiros, ano de referência 2025.

3.2 Base dos Dados

Dados complementares sobre metas e indicadores históricos de alfabetização.

Arquivo	Descrição	Linhas
meta_brasil.csv	Meta nacional de alfabetização por ano	3
meta_uf.csv	Metas por estado (2024-2030)	54
meta_municipio.csv	Metas por município	10.704
municipio.csv	Dados complementares dos municípios	23.995
uf.csv	Indicador histórico por UF	145

3.3 Decisões sobre as Fontes

Substituição da tabela de alunos: A tabela de alunos da Base dos Dados foi descontinuada durante o desenvolvimento. Optamos por substituí-la pelos Microdados Oficiais INEP AEEB 2025, que contêm dados mais detalhados e atualizados de 2,2 milhões de alunos de 27 estados. Essa decisão demonstrou maturidade técnica — encontramos um obstáculo e encontramos uma solução melhor.

Tocantins (TO): O estado do Tocantins não possui registros de rede estadual (`ID_TIPO_REDE = 2`) nos Microdados INEP AEEB 2025. O estado participa da avaliação apenas através das redes municipal e privada. Por isso, as análises por rede estadual cobrem 26 das 27 unidades federativas brasileiras.

4. Tecnologias Utilizadas

4.1 Stack Tecnológica

Tecnologia	Versão	Justificativa
Python	3.13	Linguagem principal — ecossistema rico para dados, ampla adoção em engenharia de dados
Pandas	2.x	Manipulação e transformação de DataFrames — padrão da indústria
PyArrow	latest	Leitura/escrita de arquivos Parquet com alta performance
Boto3	latest	SDK oficial AWS para Python — acesso programático ao S3
AWS S3	—	Data Lake escalável, durável e de baixo custo
Parquet	—	Formato colunar com compressão eficiente — 83% menor que CSV
Git + GitHub	—	Versionamento, branches, Pull Requests e histórico de desenvolvimento
Python-dotenv	—	Gerenciamento seguro de credenciais via arquivo .env
WeasyPrint	—	Conversão de Markdown para PDF para documentação

4.2 Por que AWS S3?

- **Custo:** armazenamento a \$0.023/GB — praticamente zero para nosso volume
- **Escalabilidade:** suporta desde KB até PB sem mudança de arquitetura
- **Durabilidade:** 99.999999999% de durabilidade dos dados
- **Integração:** compatível com todo o ecossistema AWS e ferramentas de BI
- **Serverless:** sem servidores para gerenciar ou pagar quando não usado

4.3 Por que Parquet?

- **Compressão:** 83% menor que CSV no nosso projeto (261MB → 45MB)
- **Performance:** leitura colunar — lê só as colunas necessárias
- **Tipagem:** preserva tipos de dados (int, float, date) — CSV trata tudo como texto
- **Compatibilidade:** padrão da indústria, suportado por Spark, Athena, BigQuery, Power BI

5. Decisões Arquiteturais

5.1 Batch vs Streaming

Critério	Batch	Streaming
Volume	Alto (2.2M registros)	Baixo (eventos individuais)
Frequência	Diária/semanal	Tempo real
Latência	Minutos	Segundos
Custo	Menor	Maior
Uso no projeto	Dados históricos INEP	Atualizações de indicadores

Decisão: Arquitetura híbrida — Batch para os dados históricos volumosos e Streaming para simular atualizações em tempo real de indicadores municipais.

5.2 Data Lake vs Data Warehouse

Critério	Data Lake (escolhido)	Data Warehouse
Flexibilidade	Alta — qualquer formato	Baixa — esquema rígido
Custo	Baixo — S3	Alto — Redshift, BigQuery
Escalabilidade	Ilimitada	Limitada pelo cluster
Governança	Manual	Automática

Decisão: Data Lake no AWS S3 pela flexibilidade e custo. A camada Gold funciona como um Data Mart — datasets pré-agregados e prontos para consumo.

5.3 Arquitetura Medalhão

Por que três camadas?

- **Bronze:** preserva os dados originais intactos — se algo der errado nas transformações, sempre podemos reprocessar a partir daqui
- **Silver:** dados limpos e integrados — a "verdade única" sobre os dados
- **Gold:** datasets otimizados para cada caso de uso — evita reprocessamento a cada consulta

5.4 Nuvem Escolhida — AWS

O projeto utilizou **AWS Academy**, disponibilizado pela FIAP, com \$50 de crédito para uso educacional. A escolha da AWS foi natural dado o acesso já disponível, além de ser a plataforma de nuvem mais utilizada no mercado.

6. Qualidade de Dados

6.1 Validações Implementadas

O script `bronze_quality.py` executa as seguintes verificações em todos os 9 arquivos da camada Bronze:

- **Duplicatas:** contagem de linhas idênticas
- **Valores ausentes:** detecção e contagem por coluna
- **Tipos de dados:** verificação de consistência
- **Volume:** contagem de linhas e colunas

6.2 Resultado do Relatório de Qualidade

```
=====
RESUMO FINAL
=====
✅ Arquivos OK:      3
⚠️ Arquivos atenção: 6
=====
```

6.3 Principais Achados

Arquivo	Status	Principal Observação
TS_ALUNO	⚠️ Atenção	628 alunos sem escola — documentado pelo INEP
TS_ESTADO	✅ OK	Sem problemas
TS_ITEM	⚠️ Atenção	Parâmetros ausentes para SP e RS — documentado pelo INEP
TS_MUNICIPIO	✅ OK	Sem problemas
meta_brasil	✅ OK	Sem problemas
meta_municipio	⚠️ Atenção	120 municípios sem taxa de alfabetização
meta_uf	⚠️ Atenção	Algumas metas futuras não definidas

Arquivo	Status	Principal Observação
municipio	☐☐ Atenção	11.547 municípios sem dados de nível de desempenho
uf	☐☐ Atenção	70 registros sem dados de nível

Importante: Todos os problemas encontrados têm explicação documentada nas fontes originais. Nenhum é crítico para as análises realizadas.

6.4 Tratamento na Camada Silver

Problema	Tratamento aplicado
Escolas sem código	Preenchido com 0 (numérico)
Municípios sem nome	Preenchido com 'NAO_IDENTIFICADO'
Proficiência ausente	Preenchido com -1 (indica ausência, não zero)
Blocos sem resposta	Preenchido com 'SEM_BLOCO'
Metas não definidas	Preenchido com -1

7. Monitoramento da Pipeline

7.1 Estratégia de Monitoramento

O script `pipeline_monitor.py` implementa observabilidade completa da pipeline, verificando a saúde de todas as camadas em uma única execução.

7.2 O que é monitorado

Verificação	Descrição
Presença de arquivos	Confirma que todos os 24 arquivos esperados existem no S3
Volume por camada	Mede o tamanho em MB de cada camada
Contagem de arquivos	Quantos arquivos existem em cada camada
Status do Streaming	Eventos pendentes vs processados
Alertas	Identifica arquivos faltantes e emite alertas

7.3 Resultado do Monitoramento

```
=====
RELATÓRIO DE SAÚDE DA PIPELINE
Gerado em: 08/07/2026 14:51:42
=====
```

```
🚩 Status Geral: ✅ SAUDÁVEL
```

```
Arquivos OK: 24
```

```
Arquivos faltando: 0
```

```
📁 Uso de Armazenamento:
```

```
Bronze: 261.45 MB (10 arquivos)
```

```
Silver: 45.13 MB (7 arquivos)
```

```
Gold: 0.97 MB (10 arquivos)
```

```
Streaming: 0.0 MB (4 arquivos)
```

```
Total: 307.55 MB
```

```
📡 Streaming:
```

```
Eventos processados: 3
```

```
Eventos pendentes: 0
```

```
Status: ✅ OK
```

```
✅ Todos os arquivos estão presentes e a pipeline está saudável!
```

7.4 Resultado do Último Monitoramento

```
Status Geral: SAUDÁVEL
```

```
Arquivos verificados: 24/24
```

```
Bronze: 261.45 MB (10 arquivos)
```

```
Silver: 45.13 MB (7 arquivos)
```

```
Gold: 0.97 MB (10 arquivos)
```

```
Streaming: 0.00 MB (4 arquivos)
```

```
Total: 307.55 MB
```

```
Streaming: 3 eventos processados, 0 pendentes
```

7.5 Streaming — Observabilidade

O pipeline de Streaming gera logs JSON estruturados a cada execução do Consumer, registrando: - ID único da execução - Timestamp exato - Total de eventos processados - Detalhes de cada evento (município, tendência)

8. FinOps — Otimização de Custos

8.1 Estratégias Implementadas

1. Formato Parquet

A escolha do Parquet para as camadas Silver e Gold resultou em redução significativa de armazenamento:

```
Bronze (CSV): 261.45 MB
Silver (Parquet): 45.13 MB
Redução: 83% menos espaço
```

```
Detalhe do maior arquivo:
```

```
TS_ALUNO.csv: 257 MB (CSV)
```

```
aluno.parquet: 44 MB (Parquet)
```

```
Redução: 83% neste arquivo
```

2. Particionamento por Data

Todos os arquivos são organizados por data de processamento:

```
bronze/inep/2026-06-10/
silver/inep/2026-06-15/
```

Isso permite deletar partições antigas sem afetar dados recentes, reduzindo custos de armazenamento ao longo do tempo.

3. Arquitetura Serverless

- Sem servidores EC2 rodando 24/7
- Scripts Python executados sob demanda
- Zero custo quando a pipeline não está rodando

4. Estimativa de Custo Mensal

Recurso	Volume	Custo/GB	Custo Mensal
S3 Bronze	261.45 MB	\$0.023/GB	\$0.006
S3 Silver	45.13 MB	\$0.023/GB	\$0.001
S3 Gold	0.97 MB	\$0.023/GB	\$0.00002
Total	307.55 MB		~\$0.007/mês

Custo praticamente zero para esse volume — demonstrando eficiência máxima de FinOps.

8.2 Comparativo de Custos

Abordagem	Custo Estimado/mês	Nossa Abordagem
EC2 + RDS	~\$50-100	☐
Redshift	~\$180	☐
S3 + Serverless	~\$0.007	☐

9. Aplicação em Inteligência Artificial

9.1 A Camada Gold como Base para IA

Os datasets da camada Gold foram projetados para alimentar diretamente modelos de Machine Learning e análises de IA, com features já calculadas e normalizadas.

9.2 Caso de Uso 1 — Predição de Alfabetização

Objetivo: prever a taxa de alfabetização futura de um município com base em seu histórico e características.

Features disponíveis:

```
features = [  
    'perc_alunos_alfabetizados', # taxa atual  
    'media_lingua_portuguesa', # desempenho médio  
    'distancia_meta_2024',      # distância da meta  
    'distancia_meta_2025',  
    'esforco_por_ano',          # esforço necessário  
    'nivel_municipio',          # classificação atual  
    'regiao',                   # região geográfica  
]  
  
target = 'taxa_alfabetizacao_2026' # o que queremos prever
```

Modelos sugeridos: - XGBoost ou Random Forest para regressão - Acurácia esperada: >85% com os dados disponíveis

9.3 Caso de Uso 2 — Clustering de Municípios

Objetivo: agrupar municípios com perfis similares para orientar políticas públicas regionalizadas.

Abordagem: - K-Means ou DBSCAN sobre as features da Gold - Identificação de clusters de vulnerabilidade educacional - Priorização de recursos por cluster

9.4 Caso de Uso 3 — Sistema de Alertas Inteligentes

Objetivo: usar o Streaming para detectar municípios com queda brusca no indicador e acionar alertas automáticos.

Fluxo:

```
Novo resultado → Producer → Consumer → Modelo de detecção
                                     → Alerta se queda > 5pp
                                     → Dashboard atualizado
```

9.5 Potencial de Impacto

Com os dados organizados nessa pipeline, é possível: - Identificar **404 municípios críticos** que precisam de intervenção urgente - Prever quais municípios atingirão a meta de 2030 sem intervenção - Simular o impacto de políticas públicas antes de implementá-las - Monitorar em tempo real via Streaming qualquer deterioração nos indicadores

10. Resultados Encontrados

10.1 Panorama Nacional (2025)

```
📄 PAINEL EXECUTIVO — BRASIL:
  Taxa Nacional de Alfabetizacao (%): 66.15
  Meta Nacional 2030 (%): 100.0
  Distancia da Meta 2030 (pp): 33.85
  Melhor Estado: GO
  Taxa Melhor Estado (%): 84.09
  Pior Estado: RR
  Taxa Pior Estado (%): 39.24
  Diferenca Melhor vs Pior (pp): 44.85
  Municipios em Nivel Critico: 404
  Ano de Referencia: 2025

📄 Salvando painel_executivo_brasil.parquet na Gold...
✅ Salvo em: s3://tech-challenge-alfabetizacao/gold/2026-07-08/painel_executivo_brasil.parquet
📊 10 linhas, 2 colunas
```

```
Crianças avaliadas:      1.969.921
Crianças alfabetizadas:  1.303.038
Taxa nacional:           66.15%
Meta 2030:               100%
Distância da meta:       33.85 pontos percentuais
```

Interpretação: O Brasil alfabetizou 66,15% das crianças avaliadas em 2025. Para atingir a meta de 100% até 2030, o país precisa avançar em média **5,6 pontos percentuais por ano** nos próximos 6 anos — um desafio significativo mas monitorável com dados.

10.2 Ranking de Estados (Rede Estadual)

📄 TOP 5 ESTADOS MAIS ALFABETIZADOS:

ranking_nacional	sigla_uf	regiao	perc_alunos_alfabetizados	classificacao
1	GO	Centro-Oeste	84.09	ABAIXO_DA_META
2	ES	Sudeste	83.89	ABAIXO_DA_META
3	PR	Sul	83.26	ABAIXO_DA_META
4	PI	Nordeste	83.15	ABAIXO_DA_META
5	RJ	Sudeste	81.13	ABAIXO_DA_META

📄 5 ESTADOS QUE MAIS PRECISAM DE ATENÇÃO:

ranking_nacional	sigla_uf	regiao	perc_alunos_alfabetizados	classificacao
26	RR	Norte	39.24	ABAIXO_DA_META
25	BA	Nordeste	43.98	ABAIXO_DA_META
24	AP	Norte	47.70	ABAIXO_DA_META
23	AL	Nordeste	49.95	ABAIXO_DA_META
22	MS	Centro-Oeste	51.71	ABAIXO_DA_META

```
1° Goiás (GO):      84.09% ← Centro-Oeste lidera
2° Espírito Santo (ES): 83.89%
3° Paraná (PR):      83.26%
4° Piauí (PI):        83.15% ← surpreende positivamente
5° Rio de Janeiro (RJ): 81.13%
...
22° Mato Grosso do Sul: 51.71%
23° Alagoas (AL):      49.95%
24° Amapá (AP):        47.70%
25° Roraima (RR):      39.24% ← menos da metade alfabetizada
```

Diferença entre 1° e 25°: 44.85 pontos percentuais

Interpretação: A desigualdade entre estados é alarmante — Roraima tem menos da metade da taxa de alfabetização de Goiás. Isso evidencia a necessidade de políticas públicas diferenciadas por região.

10.3 Distribuição dos Municípios por Nível

📊 Criando painel de municípios...

✅ 12,416 municípios analisados

Distribuição por nível:

BOM: 3952 municípios (31.83%)
MÉDIO: 3754 municípios (30.24%)
BAIXO: 2650 municípios (21.34%)
EXCELENTE: 1656 municípios (13.34%)
CRÍTICO: 404 municípios (3.25%)

```
EXCELENTE (>90%): 1.656 municípios (13.34%)
BOM (75-90%):      3.952 municípios (31.83%)
MÉDIO (60-75%):    3.754 municípios (30.24%)
BAIXO (40-60%):    2.650 municípios (21.34%)
CRÍTICO (<40%):     404 municípios (3.25%)
```

Interpretação: Apenas 13,34% dos municípios atingem nível excelente. Mais preocupante: **404 municípios** têm menos de 40% das crianças alfabetizadas — esses são os alvos prioritários para intervenção.

10.4 Análise Regional

A pipeline permite identificar padrões regionais claros:

Região	Tendência
Sul e Sudeste	Melhores taxas gerais

Região	Tendência
Centro-Oeste	Goiás lidera surpreendentemente
Nordeste	Heterogêneo — Piauí surpreende positivamente
Norte	Maiores desafios — RR, AP com taxas críticas

10.5 Streaming — Eventos Processados

```
=====
🔍 Verificando fila de eventos pendentes...
✅ 3 eventos encontrados na fila

⚙️ Processando evento: evt_20260708150203_4308
📍 Município: Laranja da Terra (ES)
📊 Indicador: 95.65% → 93.36%
📉 Tendência: PIORA (-2.29 pontos)
✅ Evento processado com sucesso
📁 Movido para: streaming/eventos_processados/evt_20260708150203_4308.json

⚙️ Processando evento: evt_20260708150208_4298
📍 Município: Torixoréu (MT)
📊 Indicador: 91.39% → 93.46%
📈 Tendência: MELHORA (+2.07 pontos)
✅ Evento processado com sucesso
📁 Movido para: streaming/eventos_processados/evt_20260708150208_4298.json

⚙️ Processando evento: evt_20260708150214_5236
📍 Município: Venda Nova do Imigrante (ES)
📊 Indicador: 89.6% → 89.92%
📈 Tendência: MELHORA (+0.32 pontos)
✅ Evento processado com sucesso
📁 Movido para: streaming/eventos_processados/evt_20260708150214_5236.json

📄 Log de execução salvo: s3://tech-challenge-alfabetizacao/streaming/logs/run_20260708150226.json

=====
✅ 3 EVENTOS PROCESSADOS!
=====
```

Durante os testes, 3 eventos foram simulados e processados com sucesso: - Laranja da Terra (ES): PIORA(-2.29 pontos) - Torixoréu (MT): MELHORA(+2.07 pontos) - Venda Nova do Imigrante (ES): MELHORA(+0.32 pontos)

11. Governança de Dados

11.1 Segurança

- Credenciais AWS armazenadas em `.env` (nunca versionado no GitHub)
- `.gitignore` configurado para proteger arquivos sensíveis
- Dados seguem a **LGPD** — microdados sem identificação pessoal (conforme documentado pelo INEP)

11.2 Rastreabilidade

- Todos os arquivos particionados por data de processamento
- Histórico completo de transformações via commits no GitHub
- Logs de execução do Streaming registrados no S3

Branches

Overview

Active

Stale

All

Q Search branches...

Branch	Updated	Check status	Behind	Ahead	Pull request
develop	41 minutes ago		0	15	...
feature/monitoring	2 days ago		0	14	...
feature/streaming	last week		0	13	...
feature/gold-layer	2 weeks ago		0	12	...
feature/silver-layer	3 weeks ago		0	11	...
feature/bronze-layer	last month		0	10	...

11.3 Reprodutibilidade

- `requirements.txt` com todas as dependências
- `.env.example` com template de configuração
- README com guia passo a passo de execução

12. Conclusão

Este projeto demonstrou que é possível construir uma pipeline de dados robusta, escalável e de baixo custo para monitorar um indicador educacional crítico para o Brasil.

Principais conquistas técnicas:

- Pipeline híbrida Batch + Streaming funcionando na AWS
- Arquitetura Medalhão com 3 camadas bem definidas
- 2,2 milhões de registros processados com 83% de redução no armazenamento
- 9 datasets analíticos prontos para dashboards e IA
- Monitoramento automatizado da saúde da pipeline

Impacto potencial:

Os dados organizados por esta pipeline permitem identificar os **404 municípios críticos** que precisam de intervenção urgente, apoiar decisões de política pública baseadas em evidências e monitorar em tempo real o progresso do Brasil em direção à meta de alfabetização universal até 2030.