

Documentação Técnica — Tech Challenge Fase 2

Pipeline Híbrida para Análise da Alfabetização no Brasil

Instituição: FIAP PosTech

Curso: AI Scientist

Aluno: Guilherme Diniz Leocadio

Data: Julho de 2026

Repositório: <https://github.com/GuilhermeDinizLeocadio/tech-challenge-fase2>

1. Contexto do Problema

1.1 O Desafio da Alfabetização no Brasil

A alfabetização na infância é um dos pilares fundamentais para o desenvolvimento educacional, social e econômico do Brasil. Crianças que chegam ao 3º ano do ensino fundamental sem saber ler e escrever carregam essa desvantagem por toda a vida escolar, impactando diretamente suas perspectivas profissionais e sociais.

O **Compromisso Nacional Criança Alfabetizada**, instituído pelo Decreto nº 11.556 de 12 de junho de 2023, estabelece a meta de que todas as crianças brasileiras estejam alfabetizadas até o final do **2º ano do ensino fundamental até 2030**, mobilizando União, estados, Distrito Federal e municípios.

1.2 O Indicador Criança Alfabetizada

Para monitorar esse compromisso, o INEP realizou em 2023 a **Pesquisa Alfabetiza Brasil**, definindo o ponto de corte de **743 pontos na escala de proficiência do SAEB** como nível mínimo de alfabetização. Com base nesse parâmetro, foi criado o **Indicador Criança Alfabetizada**, que expressa o percentual de estudantes que atingem esse patamar.

1.3 O Problema de Dados

Os dados sobre alfabetização estão distribuídos em múltiplas fontes heterogêneas:

- Microdados das avaliações estaduais** (INEP/AEEB) — dados individuais por aluno
- Metas nacionais e regionais** (Base dos Dados) — objetivos por estado e município
- Dados territoriais** — informações geográficas e socioeconômicas

Sem uma pipeline integrada, é impossível responder perguntas estratégicas como: - Quais estados estão no caminho certo para atingir a meta de 2030? - Quais municípios precisam de intervenção urgente? - Qual é a magnitude da desigualdade regional na alfabetização? - Como a taxa de alfabetização evoluiu ao longo do tempo?

1.4 Objetivo do Projeto

Construir uma **pipeline híbrida de dados** (Batch + Streaming) que integre diferentes fontes relacionadas ao indicador de alfabetização, garantindo qualidade, escalabilidade e eficiência de custos em ambiente de nuvem AWS, produzindo datasets analíticos prontos para dashboards e modelos de Inteligência Artificial.


2. Arquitetura da Solução

2.1 Visão Geral

A solução implementa a **Arquitetura Medalhão** com três camadas de dados, combinada com uma pipeline de Streaming para eventos em tempo real, toda hospedada na AWS S3.

2.2 Diagrama da Pipeline





tech-challenge-alfabetizacao

Informações

Objetos

Metadados

Propriedades

Permissões

Métricas

Gerenciamento

Sistemas de arquivos (novo)

Pontos de acesso

Objetos (4)

Copiar URI do S3

Copiar URL

Fazer download

Abrir L2

Excluir

Ações ▾

Criar pasta

Carregar

Os objetos são as entidades fundamentais armazenadas no Amazon S3. Você pode usar o [inventário do Amazon S3](#) para obter uma lista de todos os objetos em seu bucket. Para outras pessoas acessarem seus objetos, você precisará conceder permissões explicitamente a eles. [Saiba mais](#)

Q Localizar objetos por prefixo

< 1 >

☐	Nome	Tipo	Última modificação	Tamanho	Classe de armazenamento
☐	bronze/	Pasta	-		- -
☐	gold/	Pasta	-		- -
☐	silver/	Pasta	-		- -
☐	streaming/	Pasta	-		- -

2.3 Componentes da Arquitetura

Componente	Tecnologia	Responsabilidade
Data Lake	AWS S3	Armazenamento das 3 camadas
Ingestão Batch	Python + Boto3	Coleta e envio dos CSVs para S3
Transformação	Python + Pandas	Limpeza e padronização

Componente	Tecnologia	Responsabilidade
Serialização	PyArrow + Parquet	Formato eficiente Silver/Gold
Streaming	Python + S3	Eventos em tempo real simulados
Qualidade	Scripts Python	Validação e monitoramento
Versionamento	Git + GitHub	Controle de código e histórico

2.4 Fluxo de Dados Detalhado

Batch (dados históricos): 1. Scripts Python coletam os CSVs das fontes originais 2. Arquivos são enviados ao S3 na camada Bronze (sem modificações) 3. Scripts de transformação lêem do Bronze, limpam e salvam na Silver em Parquet 4. Scripts de agregação lêem da Silver e criam datasets analíticos na Gold

Streaming (eventos em tempo real): 1. Producer gera eventos simulados com novos indicadores municipais 2. Eventos são salvos como JSON na fila `streaming/eventos_pendentes/` 3. Consumer processa cada evento, calcula tendência e move para `eventos_processados/` 4. Log de execução é registrado em `streaming/logs/`

3. Fontes de Dados

3.1 INEP — Microdados AEEB 2025

Fonte principal do projeto. Microdados das Avaliações Estaduais da Educação Básica de 2025, disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira.

Arquivo	Descrição	Linhas	Tamanho
TS_ALUNO.csv	Dados individuais dos alunos avaliados	2.222.792	257 MB
TS_ESTADO.csv	Resultados agregados por estado/UF	80	6 KB
TS_MUNICIPIO.csv	Resultados agregados por município	12.416	1.5 MB
TS_ITEM.csv	Itens de prova utilizados nas avaliações	1.960	193 KB

Cobertura: 27 estados brasileiros, ano de referência 2025.

3.2 Base dos Dados

Dados complementares sobre metas e indicadores históricos de alfabetização.

Arquivo	Descrição	Linhas
meta_brasil.csv	Meta nacional de alfabetização por ano	3
meta_uf.csv	Metas por estado (2024-2030)	54
meta_municipio.csv	Metas por município	10.704
municipio.csv	Dados complementares dos municípios	23.995
uf.csv	Indicador histórico por UF	145

3.3 Decisões sobre as Fontes

Substituição da tabela de alunos: A tabela de alunos da Base dos Dados foi descontinuada durante o desenvolvimento. Optamos por substituí-la pelos Microdados Oficiais INEP AEEB 2025, que contêm dados mais detalhados e atualizados de 2,2 milhões de alunos de 27 estados. Essa decisão demonstrou maturidade técnica — encontramos um obstáculo e encontramos uma solução melhor.

Tocantins (TO): O estado do Tocantins não possui registros de rede estadual (`ID_TIPO_REDE = 2`) nos Microdados INEP AEEB 2025. O estado participa da avaliação apenas através das redes municipal e privada. Por isso, as análises por rede estadual cobrem 26 das 27 unidades federativas brasileiras.

4. Tecnologias Utilizadas

4.1 Stack Tecnológica

Tecnologia	Versão	Justificativa
Python	3.13	Linguagem principal — ecossistema rico para dados, ampla adoção em engenharia de dados
Pandas	2.x	Manipulação e transformação de DataFrames — padrão da indústria
PyArrow	latest	Leitura/escrita de arquivos Parquet com alta performance
Boto3	latest	SDK oficial AWS para Python — acesso programático ao S3
AWS S3	—	Data Lake escalável, durável e de baixo custo
Parquet	—	Formato colunar com compressão eficiente — 83% menor que CSV
Git + GitHub	—	Versionamento, branches, Pull Requests e histórico de desenvolvimento
Python-dotenv	—	Gerenciamento seguro de credenciais via arquivo .env
WeasyPrint	—	Conversão de Markdown para PDF para documentação

4.2 Por que AWS S3?

- **Custo:** armazenamento a \$0.023/GB — praticamente zero para nosso volume
- **Escalabilidade:** suporta desde KB até PB sem mudança de arquitetura
- **Durabilidade:** 99.999999999% de durabilidade dos dados
- **Integração:** compatível com todo o ecossistema AWS e ferramentas de BI
- **Serverless:** sem servidores para gerenciar ou pagar quando não usado

4.3 Por que Parquet?

- **Compressão:** 83% menor que CSV no nosso projeto (261MB → 45MB)
- **Performance:** leitura colunar — lê só as colunas necessárias
- **Tipagem:** preserva tipos de dados (int, float, date) — CSV trata tudo como texto
- **Compatibilidade:** padrão da indústria, suportado por Spark, Athena, BigQuery, Power BI

5. Decisões Arquiteturais

5.1 Batch vs Streaming

Critério	Batch	Streaming
Volume	Alto (2.2M registros)	Baixo (eventos individuais)
Frequência	Diária/semanal	Tempo real
Latência	Minutos	Segundos
Custo	Menor	Maior
Uso no projeto	Dados históricos INEP	Atualizações de indicadores

Decisão: Arquitetura híbrida — Batch para os dados históricos volumosos e Streaming para simular atualizações em tempo real de indicadores municipais.

5.2 Data Lake vs Data Warehouse

Critério	Data Lake (escolhido)	Data Warehouse
Flexibilidade	Alta — qualquer formato	Baixa — esquema rígido
Custo	Baixo — S3	Alto — Redshift, BigQuery
Escalabilidade	Ilimitada	Limitada pelo cluster
Governança	Manual	Automática

Decisão: Data Lake no AWS S3 pela flexibilidade e custo. A camada Gold funciona como um Data Mart — datasets pré-agregados e prontos para consumo.

5.3 Arquitetura Medalhão

Por que três camadas?

- **Bronze:** preserva os dados originais intactos — se algo der errado nas transformações, sempre podemos reprocessar a partir daqui
- **Silver:** dados limpos e integrados — a "verdade única" sobre os dados
- **Gold:** datasets otimizados para cada caso de uso — evita reprocessamento a cada consulta

5.4 Nuvem Escolhida — AWS

O projeto utilizou **AWS Academy**, disponibilizado pela FIAP, com \$50 de crédito para uso educacional. A escolha da AWS foi natural dado o acesso já disponível, além de ser a plataforma de nuvem mais utilizada no mercado.

6. Qualidade de Dados

6.1 Validações Implementadas

O script `bronze_quality.py` executa as seguintes verificações em todos os 9 arquivos da camada Bronze:

- **Duplicatas:** contagem de linhas idênticas
- **Valores ausentes:** detecção e contagem por coluna
- **Tipos de dados:** verificação de consistência
- **Volume:** contagem de linhas e colunas

6.2 Resultado do Relatório de Qualidade

```
=====
RESUMO FINAL
=====
✅ Arquivos OK:      3
⚠️ Arquivos atenção: 6
=====
```

6.3 Principais Achados

Arquivo	Status	Principal Observação
TS_ALUNO	⚠️ Atenção	628 alunos sem escola — documentado pelo INEP
TS_ESTADO	✅ OK	Sem problemas
TS_ITEM	⚠️ Atenção	Parâmetros ausentes para SP e RS — documentado pelo INEP
TS_MUNICIPIO	✅ OK	Sem problemas
meta_brasil	✅ OK	Sem problemas
meta_municipio	⚠️ Atenção	120 municípios sem taxa de alfabetização
meta_uf	⚠️ Atenção	Algumas metas futuras não definidas

Arquivo	Status	Principal Observação
municipio	☐☐ Atenção	11.547 municípios sem dados de nível de desempenho
uf	☐☐ Atenção	70 registros sem dados de nível

Importante: Todos os problemas encontrados têm explicação documentada nas fontes originais. Nenhum é crítico para as análises realizadas.

6.4 Tratamento na Camada Silver

Problema	Tratamento aplicado
Escolas sem código	Preenchido com 0 (numérico)
Municípios sem nome	Preenchido com 'NAO_IDENTIFICADO'
Proficiência ausente	Preenchido com -1 (indica ausência, não zero)
Blocos sem resposta	Preenchido com 'SEM_BLOCO'
Metas não definidas	Preenchido com -1

7. Monitoramento da Pipeline

7.1 Estratégia de Monitoramento

O script `pipeline_monitor.py` implementa observabilidade completa da pipeline, verificando a saúde de todas as camadas em uma única execução.

7.2 O que é monitorado

Verificação	Descrição
Presença de arquivos	Confirma que todos os 24 arquivos esperados existem no S3
Volume por camada	Mede o tamanho em MB de cada camada
Contagem de arquivos	Quantos arquivos existem em cada camada
Status do Streaming	Eventos pendentes vs processados
Alertas	Identifica arquivos faltantes e emite alertas

7.3 Resultado do Monitoramento

```
=====
RELATÓRIO DE SAÚDE DA PIPELINE
Gerado em: 08/07/2026 14:51:42
=====
```

🚩 Status Geral: ✅ SAUDÁVEL

Arquivos OK: 24

Arquivos faltando: 0

📁 Uso de Armazenamento:

Bronze: 261.45 MB (10 arquivos)

Silver: 45.13 MB (7 arquivos)

Gold: 0.97 MB (10 arquivos)

Streaming: 0.0 MB (4 arquivos)

Total: 307.55 MB

📡 Streaming:

Eventos processados: 3

Eventos pendentes: 0

Status: ✅ OK

✅ Todos os arquivos estão presentes e a pipeline está saudável!

7.4 Resultado do Último Monitoramento

Status Geral: SAUDÁVEL

Arquivos verificados: 24/24

Bronze: 261.45 MB (10 arquivos)

Silver: 45.13 MB (7 arquivos)

Gold: 0.97 MB (10 arquivos)

Streaming: 0.00 MB (4 arquivos)

Total: 307.55 MB

Streaming: 3 eventos processados, 0 pendentes

7.5 Streaming — Observabilidade

O pipeline de Streaming gera logs JSON estruturados a cada execução do Consumer, registrando: - ID único da execução - Timestamp exato - Total de eventos processados - Detalhes de cada evento (município, tendência)

8. FinOps — Otimização de Custos

8.1 Estratégias Implementadas

1. Formato Parquet

A escolha do Parquet para as camadas Silver e Gold resultou em redução significativa de armazenamento:

```
Bronze (CSV):      261.45 MB
Silver (Parquet):  45.13 MB
Redução:           83% menos espaço
```

Detalhe do maior arquivo:

```
TS_ALUNO.csv:      257 MB (CSV)
aluno.parquet:     44 MB (Parquet)
Redução:           83% neste arquivo
```

2. Particionamento por Data

Todos os arquivos são organizados por data de processamento:

```
bronze/inep/2026-06-10/
silver/inep/2026-06-15/
```

Isso permite deletar partições antigas sem afetar dados recentes, reduzindo custos de armazenamento ao longo do tempo.

3. Arquitetura Serverless

- Sem servidores EC2 rodando 24/7
- Scripts Python executados sob demanda
- Zero custo quando a pipeline não está rodando

4. Estimativa de Custo Mensal

Recurso	Volume	Custo/GB	Custo Mensal
S3 Bronze	261.45 MB	\$0.023/GB	\$0.006
S3 Silver	45.13 MB	\$0.023/GB	\$0.001
S3 Gold	0.97 MB	\$0.023/GB	\$0.00002
Total	307.55 MB		~\$0.007/mês

Custo praticamente zero para esse volume — demonstrando eficiência máxima de FinOps.

8.2 Comparativo de Custos

Abordagem	Custo Estimado/mês	Nossa Abordagem
EC2 + RDS	~\$50-100	☐
Redshift	~\$180	☐
S3 + Serverless	~\$0.007	☐

9. Aplicação em Inteligência Artificial

9.1 A Camada Gold como Base para IA

Os datasets da camada Gold foram projetados para alimentar diretamente modelos de Machine Learning e análises de IA, com features já calculadas e normalizadas.

9.2 Caso de Uso 1 — Predição de Alfabetização

Objetivo: prever a taxa de alfabetização futura de um município com base em seu histórico e características.

Features disponíveis:

```
features = [  
    'perc_alunos_alfabetizados', # taxa atual  
    'media_lingua_portuguesa', # desempenho médio  
    'distancia_meta_2024',      # distância da meta  
    'distancia_meta_2025',  
    'esforco_por_ano',          # esforço necessário  
    'nivel_municipio',          # classificação atual  
    'regiao',                   # região geográfica  
]  
  
target = 'taxa_alfabetizacao_2026' # o que queremos prever
```

Modelos sugeridos: - XGBoost ou Random Forest para regressão - Acurácia esperada: >85% com os dados disponíveis

9.3 Caso de Uso 2 — Clustering de Municípios

Objetivo: agrupar municípios com perfis similares para orientar políticas públicas regionalizadas.

Abordagem: - K-Means ou DBSCAN sobre as features da Gold - Identificação de clusters de vulnerabilidade educacional - Priorização de recursos por cluster

9.4 Caso de Uso 3 — Sistema de Alertas Inteligentes

Objetivo: usar o Streaming para detectar municípios com queda brusca no indicador e acionar alertas automáticos.

Fluxo:

```
Novo resultado → Producer → Consumer → Modelo de detecção
                                     → Alerta se queda > 5pp
                                     → Dashboard atualizado
```

9.5 Potencial de Impacto

Com os dados organizados nessa pipeline, é possível: - Identificar **404 municípios críticos** que precisam de intervenção urgente - Prever quais municípios atingirão a meta de 2030 sem intervenção - Simular o impacto de políticas públicas antes de implementá-las - Monitorar em tempo real via Streaming qualquer deterioração nos indicadores

10. Resultados Encontrados

10.1 Panorama Nacional (2025)

```
📄 PAINEL EXECUTIVO — BRASIL:
  Taxa Nacional de Alfabetizacao (%): 66.15
  Meta Nacional 2030 (%): 100.0
  Distancia da Meta 2030 (pp): 33.85
  Melhor Estado: GO
  Taxa Melhor Estado (%): 84.09
  Pior Estado: RR
  Taxa Pior Estado (%): 39.24
  Diferenca Melhor vs Pior (pp): 44.85
  Municipios em Nivel Critico: 404
  Ano de Referencia: 2025

📄 Salvando painel_executivo_brasil.parquet na Gold...
✅ Salvo em: s3://tech-challenge-alfabetizacao/gold/2026-07-08/painel_executivo_brasil.parquet
📄 10 linhas, 2 colunas
```

```
Crianças avaliadas:      1.969.921
Crianças alfabetizadas:  1.303.038
Taxa nacional:           66.15%
Meta 2030:               100%
Distância da meta:       33.85 pontos percentuais
```

Interpretação: O Brasil alfabetizou 66,15% das crianças avaliadas em 2025. Para atingir a meta de 100% até 2030, o país precisa avançar em média **5,6 pontos percentuais por ano** nos próximos 6 anos — um desafio significativo mas monitorável com dados.

10.2 Ranking de Estados (Rede Estadual)

📄 TOP 5 ESTADOS MAIS ALFABETIZADOS:

ranking_nacional	sigla_uf	regiao	perc_alunos_alfabetizados	classificacao
1	GO	Centro-Oeste	84.09	ABAIXO_DA_META
2	ES	Sudeste	83.89	ABAIXO_DA_META
3	PR	Sul	83.26	ABAIXO_DA_META
4	PI	Nordeste	83.15	ABAIXO_DA_META
5	RJ	Sudeste	81.13	ABAIXO_DA_META

📄 5 ESTADOS QUE MAIS PRECISAM DE ATENÇÃO:

ranking_nacional	sigla_uf	regiao	perc_alunos_alfabetizados	classificacao
26	RR	Norte	39.24	ABAIXO_DA_META
25	BA	Nordeste	43.98	ABAIXO_DA_META
24	AP	Norte	47.70	ABAIXO_DA_META
23	AL	Nordeste	49.95	ABAIXO_DA_META
22	MS	Centro-Oeste	51.71	ABAIXO_DA_META

```
1° Goiás (GO):      84.09% ← Centro-Oeste lidera
2° Espírito Santo (ES): 83.89%
3° Paraná (PR):      83.26%
4° Piauí (PI):        83.15% ← surpreende positivamente
5° Rio de Janeiro (RJ): 81.13%
...
22° Mato Grosso do Sul: 51.71%
23° Alagoas (AL):      49.95%
24° Amapá (AP):        47.70%
25° Roraima (RR):      39.24% ← menos da metade alfabetizada
```

Diferença entre 1° e 25°: 44.85 pontos percentuais

Interpretação: A desigualdade entre estados é alarmante — Roraima tem menos da metade da taxa de alfabetização de Goiás. Isso evidencia a necessidade de políticas públicas diferenciadas por região.

10.3 Distribuição dos Municípios por Nível

📄 PAINEL EXECUTIVO – BRASIL:

```
Taxa Nacional de Alfabetizacao (%): 66.15
Meta Nacional 2030 (%): 100.0
Distancia da Meta 2030 (pp): 33.85
Melhor Estado: GO
Taxa Melhor Estado (%): 84.09
Pior Estado: RR
Taxa Pior Estado (%): 39.24
Diferenca Melhor vs Pior (pp): 44.85
Municípios em Nivel Critico: 404
Ano de Referencia: 2025
```

📄 Salvando painel_executivo_brasil.parquet na Gold...

```
✅ Salvo em: s3://tech-challenge-alfabetizacao/gold/2026-07-08/painel_executivo_brasil.parquet
📄 10 linhas, 2 colunas
```

```
EXCELENTE (>90%): 1.656 municípios (13.34%)
BOM (75-90%):      3.952 municípios (31.83%)
MÉDIO (60-75%):    3.754 municípios (30.24%)
BAIXO (40-60%):    2.650 municípios (21.34%)
CRÍTICO (<40%):     404 municípios (3.25%)
```

Interpretação: Apenas 13,34% dos municípios atingem nível excelente. Mais preocupante: **404 municípios** têm menos de 40% das crianças alfabetizadas — esses são os alvos prioritários para intervenção.

10.4 Análise Regional

A pipeline permite identificar padrões regionais claros:

Região	Tendência
Sul e Sudeste	Melhores taxas gerais
Centro-Oeste	Goiás lidera surpreendentemente
Nordeste	Heterogêneo — Piauí surpreende positivamente
Norte	Maiores desafios — RR, AP com taxas críticas

10.5 Streaming — Eventos Processados

```
=====
🔍 Verificando fila de eventos pendentes...
✅ 3 eventos encontrados na fila

⚙️ Processando evento: evt_20260708150203_4308
📍 Município: Laranja da Terra (ES)
📊 Indicador: 95.65% → 93.36%
📈 Tendência: PIORA (-2.29 pontos)
✅ Evento processado com sucesso
📁 Movido para: streaming/eventos_processados/evt_20260708150203_4308.json

⚙️ Processando evento: evt_20260708150208_4298
📍 Município: Torixoréu (MT)
📊 Indicador: 91.39% → 93.46%
📈 Tendência: MELHORA (+2.07 pontos)
✅ Evento processado com sucesso
📁 Movido para: streaming/eventos_processados/evt_20260708150208_4298.json

⚙️ Processando evento: evt_20260708150214_5236
📍 Município: Venda Nova do Imigrante (ES)
📊 Indicador: 89.6% → 89.92%
📈 Tendência: MELHORA (+0.32 pontos)
✅ Evento processado com sucesso
📁 Movido para: streaming/eventos_processados/evt_20260708150214_5236.json

📄 Log de execução salvo: s3://tech-challenge-alfabetizacao/streaming/logs/run_20260708150226.json

=====
✅ 3 EVENTOS PROCESSADOS!
=====
```

Durante os testes, 3 eventos foram simulados e processados com sucesso: - Laranja da Terra (ES): PIORA(-2.29 pontos) - Torixoréu (MT): MELHORA(+2.07 pontos) - Venda Nova do Imigrante (ES): MELHORA(+0.32 pontos)

11. Governança de Dados

11.1 Segurança

- Credenciais AWS armazenadas em `.env` (nunca versionado no GitHub)
- `.gitignore` configurado para proteger arquivos sensíveis
- Dados seguem a **LGPD** — microdados sem identificação pessoal (conforme documentado pelo INEP)

11.2 Rastreabilidade

- Todos os arquivos particionados por data de processamento
- Histórico completo de transformações via commits no GitHub
- Logs de execução do Streaming registrados no S3

Branches

Overview

Active

Stale

All

Q Search branches...

Branch	Updated	Check status	Behind	Ahead	Pull request
develop	41 minutes ago		0	15	...
feature/monitoring	2 days ago		0	14	...
feature/streaming	last week		0	13	...
feature/gold-layer	2 weeks ago		0	12	...
feature/silver-layer	3 weeks ago		0	11	...
feature/bronze-layer	last month		0	10	...

11.3 Reprodutibilidade

- `requirements.txt` com todas as dependências
- `.env.example` com template de configuração
- README com guia passo a passo de execução

12. Conclusão

Este projeto demonstrou que é possível construir uma pipeline de dados robusta, escalável e de baixo custo para monitorar um indicador educacional crítico para o Brasil.

Principais conquistas técnicas:

- Pipeline híbrida Batch + Streaming funcionando na AWS
- Arquitetura Medalhão com 3 camadas bem definidas
- 2,2 milhões de registros processados com 83% de redução no armazenamento
- 9 datasets analíticos prontos para dashboards e IA
- Monitoramento automatizado da saúde da pipeline

Impacto potencial:

Os dados organizados por esta pipeline permitem identificar os **404 municípios críticos** que precisam de intervenção urgente, apoiar decisões de política pública baseadas em evidências e monitorar em tempo real o progresso do Brasil em direção à meta de alfabetização universal até 2030.